

Evaluación de Métodos de Segmentación de Imágenes Usando la Base de Datos BSDS500

Francisco J. Cedano
Departamento de Ingeniería Biomédica
Universidad de Los Andes
fj.cedano803@uniandes.edu.co

Abstract

Este informe estudia dos diferentes algoritmos para segmentación de imágenes usando la base de datos BSDS500 de Berkley para evaluación de estos algoritmos en 200 imágenes. El primer algoritmo es basado en kmeans y el segundo es basado en el modelo de mezclas gaussianas (gmm). Ambos algoritmos son evaluados a partir de curvas precisión-cobertura. Se encontró que mezclas gaussianas tiene un mejor rendimiento en esta evaluación respecto a kmeans.

1. Introduction

El análisis de segmentación aplica uno o más algoritmos de segmentación con el fin de encontrar patrones escondidos o divisiones de grupos en una base de datos. Los algoritmos de segmentación forman grupos o clusters de tal manera que los datos dentro de un cluster son muy similares entre sí. La medida de similaridad puede estar definida por distancia euclidiana, distancia probabilística y otras. Los análisis de cluster son métodos de aprendizaje no supervisado y una de las tareas específicas es explorar y analizar los datos en imágenes y estimar la similaridad entre diferentes grupos. Los métodos más populares son los siguientes:

- **Kmeans:** Divide la información en k diferentes clusters basados en una distancia entre cada dato y el centroide de cada cluster.
- **Modelo de mezcla de gaussianas (GMM):** Permite separar los clusters a partir de mezclas de componentes de distribuciones normales multivariadas.
- **Segmentación jerárquica:** Permite construir clusters en multiniveles jerárquicos creando un árbol de clusters.

- **Watersheds:** Permite ver una imagen en escala de grises como un relieve topográfico, donde se interpreta el nivel de gris de un píxel como su altura en el relieve.

1.1. Objetivo

Este proyecto está enfocado en construir una función que permita segmentar una imagen de la base de datos BSDS500 con los 4 diferentes métodos expuestos anteriormente, dos de estos cuatro métodos serán usados para su evaluación con las curvas de precisión-cobertura usando las imágenes de test de la base de datos BSDS500.

Este proyecto está basado en el artículo de Pablo Arbeláez en el cual describe el estado del arte de los métodos de segmentación de imágenes y de la evaluación de estos a partir de curvas precisión-cobertura. [1]

2. Metodología

2.1. Función *Segment_by_clustering*

El primer paso en el desarrollo de este proyecto, es formular una función en matlab que tenga los siguientes parámetros de entrada :

- **Image:** Cualquier imagen en el espacio de representación rgb.
- **fs:** feature space, o espacio de representación de color, puede ser: rgb, lab, hsv, rgb+xy, lab+xy, hsv+xy.
- **cm:** clustering_method, o método de segmentación, puede ser: kmeans, gmm, watersheds o segmentación jerárquica.
- **k:** es el número de clusters en el cual se quiere segmentar la imagen.

```
función:  
my_segmentation = segment_by_clustering  
(Image, fs, cm, k)
```

La variable de salida de la función es una matriz donde cada pixel de la imagen original tiene un número asociado a su cluster correspondiente.

Segment_by_clustering Usa la función *makeform* y *applyform*. de matlab para transformar la imagen de entrada en diferentes espacios de representación de color.

En cuando a segmentación, en el método kmeans se usa la función con el mismo nombre, aunque se añaden parámetros de distancia euclidiana para estimar los diferentes clusters, como también se añade el parámetro de replicar el algoritmo al menos unas 3 veces para evitar resultados de mínimos locales. El método gmm, se usa la función *gmdistribution.fit* con el parámetro *regularize* que hace siempre positiva la matriz de covarianza, haciendo que encuentre solución efectivamente. El método de segmentación jerárquico usa las funciones *pdist* y *linkage* para construir el arbol de clusters que será ampliado en dos diferentes pirámides gaussianas. Por último, el método de segmentación de Watersheds, usa el principio de líneas divisorias de agua para encontrar bordes de una imagen a partir de una altura específica de segmentación.

En la sección de resultados se presentaran ejemplos de imagenes segmentadas a partir de estos 4 métodos.

2.2. Segmentación Imágenes Test de BSDS500

Los métodos usados para segmentación de las 200 imágenes de test de la base de datos BSDS500 fueron los métodos kmeans y gmm. Estos se seleccionaron dado su bajo costo computacional y su posible comparación con las curvas precisión-cobertura de esta misma base de datos. Se construyó para cada imagen un archivo .mat que contiene un arreglo de celdas. Cada celda representa la variable de salida de la función *Segment_by_clustering* con un valor k diferente. Se usó un valor de k de: 2, 3, 4 y 5.

La función que hace esta segmentación se explica de manera generalizada a continuación:

```
% Se lee la imagen del directorio
de Test
image=fullfile(Dir, D(i).name);
% Entra la imagen a la función
segs{1,cnt_1}=segment_by_clustering
(images{i},'lab','kmeans',k);
%Se guarda el resultado en
otro directorio
save(fullfile(DirOut,filename),'segs')
```

Este proceso se hace para los 4 diferentes clusters. Se guarda cada archivo .mat con el nombre de la imagen y la función que se almacena debe tener el nombre segs.

2.3. Evaluación de Segmentación

La evaluación de los métodos de segmentación kmeans y gmm, se llevó a cabo con la función *boundaryBench*, función en la cual sus parámetros de entrada son los siguientes:

- imaDir: Directorio de imagenes de test de la base de datos. (/home/vision/BSR/BSDS500/data/images/test)
- gtDir: Directorio de imágenes de verdad terreno. (/home/vision/BSR/BSDS500/data/groundTruth/test)
- pbDir: Directorio de los archivos .mat segmentados por el código *Segment_by_clustering*. (/home/vision/gmm), para el caso del método gmm.
- outDir: Directorio de salida de los resultados en archivos txt. (/home/vision/FJCS)

La función se corrió en el servidor de guitaca.uniandes.

3. Resultados

3.1. Función *Segment_by_clustering*

Se usó kmeans para segmentar la imagen 41006.jpg de la base de datos de evaluación con la función *Segment_by_clustering*. Se usó el espacio de representación de color Lab y k=6. (ver Figura 1.)




Figure 1. Ejemplo de segmentación usando kmeans con 6 clusters.

Se usó el método gmm con diferentes números de clusters. (ver Figura 2.)

Watersheds es un método diferente a kmeans y gmm en cuanto a la selección a priori del número de clusters. En este método se controla el umbral al cual se quiere observar el resultado de la segmentación de la imagen (ver Figura 3.)

Por último el método de segmentación jerárquica crea grupos de clustering de datos a través de una variedad de escalas mediante la creación de un grupo de árboles o dendrograma. El árbol no es un único conjunto de clusters, sino más bien una jerarquía de niveles múltiples, donde los grupos en un nivel se unen como grupos en el siguiente nivel. Esto le permite decidir el nivel o escala de agrupación que es el más apropiado para su aplicación. (ver Figura 4.)




Figure 2. Ejemplo de una imagen segmentada a partir del método gmm. (Izquierda) imagen original, (centro) imagen segmentada por gmm con $k=2$ y (derecha) imagen segmentada por gmm con $k=4$




Figure 3. Ejemplo de segmentación usando Watersheds con un umbral de 10.



Figure 4. Ejemplo de segmentación jerárquica con un umbral de 10.

3.2. Segmentación Imágenes Test de BSDS500

En total se obtuvieron 800 diferentes segmentaciones, 200 archivos .mat y en cada uno 4 celdas con 4 diferentes segmentaciones por imagen. Estos archivos se guardaron en la carpeta Evaluación_FJCSzip.

3.3. Evaluación de Segmentación

Los resultados de la evaluación están dados por tres variables: el valor F para Optima data scale (ODS), el valor F para optimal image scale (OIS) y el área bajo la curva pre-

Método	Valor ODS
kmeans	$F(0.68, 0.38) = 0.49$
gmm	$F(0.71, 0.41) = 0.52$
UCM	$F(0.73, 0.73) = 0.73$

Table 1. Resultados de F para ODS

Método	Valor OIS
kmeans	$F(0.75, 0.44) = 0.55$
gmm	$F(0.74, 0.46) = 0.57$
UCM	$F(0.77, 0.75) = 0.76$

Table 2. Resultados de F para OIS

Método	Área
kmeans	0.15
gmm	0.16
UCM	0.73

Table 3. Resultados deL área bajo la curva precisión-cobertura

cisión-cobertura. (ver Tabla 1., 2. y 3.).

ODS, usa un umbral fijo para todas las imágenes en el conjunto de datos de evaluación, calibradas para proporcionar un rendimiento óptimo en el conjunto de entrenamiento.

Por el contrario, OIS, evalúa el rendimiento de los métodos cuando el umbral (threshold) óptimo es seleccionado por otro algoritmo en función de cada imagen. Con este uno debería obtener mejores segmentaciones.[1]

4. Discusión y Conclusiones

Es evidente la inferioridad en rendimiento de los métodos kmeans y gmm respecto al método propuesto por Arbeláez [1]. Pero es gracias al método de evaluación de curvas que se puede cuantificar las diferencias en estos tres métodos.

Debido a la poca disponibilidad de equipos con alto poder computacional solo se pudieron correr 4 diferentes




Figure 5. Esta gráfica compara el rendimiento de los métodos kmeans (línea azul) y gmm (línea negra) comparados con el método de UCM (línea roja) de P. Arbeláez[1]

segmentaciones por imagen (2 a 5 clusters). Esto hace que la curva precisión-cobertura sea muy corta. Es por ello que los valores de área bajo la curva (ver Tabla 3.) no son confiables para comparar los métodos. Sin embargo, el valor F, tanto para ODS como OIS es comparable. Kmeans tiene un valor F menor que gmm aunque no es muy significativo.

En cuanto a la precisión, la cual es la fracción de instancias recuperadas que son relevantes (verdaderas positivas), el método de kmeans es menor a gmm y ambos son muy inferiores respecto a UCM y a la misma segmentación por humanos. En cambio, en cobertura, kmeans y gmm tienen valores similares a los humanos, 74% y 75% respectivamente. Esto quiere decir, que las segmentaciones de kmeans y gmm segmentan con gran porcentaje las segmentaciones que hacen los humanos, pero carecen de precisión.

Ambos métodos tiene resultados similares y se podrían mejorar usando mayor numeros de clusters en su evaluación. Al ser kmeans y gmm, un tipo de segmentación no supervisada, se podría mejorar añadiendo algún tipo de segmentación supervisada.

5. Referencias

- [1] P. Arbelaez, M. Maire, C. Fowlkes and J. Malik. "Contour Detection and Hierarchical Image Segmentation". IEEE TPAMI, Vol. 33, No. 5, pp. 898-916, May 2011..